

Marcelo Javier Werner

Análisis de Publicaciones Instagram Fundación Aprender Haciendo



Autor: Marcelo Javier Werner

Fecha: 29 de septiembre de 2026

Índice

1. Introducción	3
2. Objetivo del proyecto	4
3. Descripción del conjunto de datos	5
4. Preparación y limpieza de datos	6
4.1 Limpieza de texto	6
5. Distribución de la muestra según formatos	7
6. Análisis de likes y comentarios	7
7. Construcción de la métrica de interacciones	9
8. Asimetría y valores extremos	9
9. Concentración de las interacciones	10
10. Análisis de contenido	12
11. Asociación de palabras	13
12. Clasificación temática	14
13. Interacciones por temática	15
14. Clasificación de publicaciones de alto rendimiento	16
15. Alto rendimiento según temática	17
16. Interacción según formato	18
17. Interacción según día de la semana	19
18. Interacción según horario	21
19. Tema x formato x rendimiento	21
20. Analisis de Hashtag	23
21. Longitud de los captions	23
22. Principales hallazgos	24
23. Limitaciones del análisis	26
24. Conclusiones	28
25. Herramientas utilizadas	29

1. Introducción

Las redes sociales generan grandes cantidades de información que pueden ser utilizadas para analizar el comportamiento de las audiencias y comprender qué características presentan las publicaciones que obtienen mayores niveles de interacción.

En este proyecto se realizó un análisis exploratorio de datos sobre las publicaciones de Instagram de la Fundación Aprender Haciendo, utilizando información correspondiente a las últimas 100 publicaciones disponibles en el conjunto de datos.

El objetivo fue transformar los datos de las publicaciones en información útil para identificar patrones relacionados con:

- Nivel de interacción;
- Tipo de publicación;
- Temática del contenido;
- Día y horario de publicación;
- Extensión de los textos;
- Utilización de hashtags;
- Palabras y conceptos frecuentes;
- Concentración de las interacciones;
- Relación entre temática, formato e interacción.

El análisis fue realizado utilizando Python y Pandas, complementando el procesamiento con técnicas de limpieza y transformación de texto y visualizaciones mediante Matplotlib.

2. Objetivo del proyecto

El objetivo principal fue explorar y caracterizar el comportamiento de las publicaciones de Instagram de Fundación Aprender Haciendo, identificando patrones que permitan comprender qué características presentan las publicaciones con mayores niveles de interacción intentado encontrar patrones y hallazgos de valor.

Como objetivos específicos se plantearon:

- Explorar y limpiar el conjunto de datos.
- Analizar la distribución de likes y comentarios.
- Construir una métrica de interacción para cada publicación.
- Identificar publicaciones con valores de interacción excepcionalmente altos.
- Analizar la concentración de las interacciones.
- Clasificar las publicaciones según su temática.
- Comparar el comportamiento de las diferentes temáticas.
- Analizar diferencias entre imágenes y videos.
- Explorar la relación entre día y horario de publicación e interacción.
- Analizar el contenido textual de las publicaciones.
- Identificar palabras y asociaciones frecuentes.
- Generar visualizaciones que permitan comunicar los principales hallazgos.

3. Descripción del conjunto de datos

El dataset utilizado contiene **100 publicaciones**.

Cada registro representa una publicación individual y cuenta con información relacionada con su identificación, formato, fecha, contenido e interacción.

Entre las variables utilizadas se encuentran:

Variable	Descripción
id	Identificador único de la publicación
isVideo	Indica si la publicación corresponde a un video
likeCount	Cantidad de "Me gusta"
commentCount	Cantidad de comentarios
caption	Texto asociado a la publicación
postDate	Fecha y hora de publicación
postUrl	URL de la publicación
fecha	Fecha de publicación extraída de "postDate"
hora	Hora de publicación extraída de "postDate"
dia_semana	Día de la semana
longitud_caption	Cantidad de caracteres del texto
cantidad_hashtags	Cantidad de hashtags utilizados
caption_limpio	Texto procesado para análisis
palabras	Palabras obtenidas del texto
palabras_limpias	Palabras luego de eliminar palabras vacías
tema	Categoría temática asignada
tiene_caption	Indicador de existencia de texto

Previamente se verificó la existencia de registros duplicados y **no se encontraron publicaciones duplicadas**.

4. Preparación y limpieza de los datos

Antes de realizar el análisis se llevó adelante una etapa de exploración y preparación del dataset.

Se verificaron los tipos de datos, valores faltantes, duplicados y consistencia de las variables.

Para el análisis temporal se utilizó la variable `postDate`, a partir de la cual se generaron variables adicionales:

- fecha;
- hora;
- día de la semana.

Esto permitió posteriormente estudiar el comportamiento de las publicaciones según diferentes momentos de publicación.

4.1 Limpieza del texto

Para analizar el contenido de las publicaciones se realizó un proceso de normalización del campo `caption`.

Entre las operaciones realizadas se incluyeron:

- Reemplazo de valores nulos;
- Conversión a minúsculas;
- Eliminación de URLs;
- Eliminación de hashtags para determinados análisis;
- Eliminación de menciones;
- Eliminación de caracteres especiales;
- Separación del texto en palabras;
- Eliminación de palabras vacías o *stopwords*.

Esto permitió generar variables específicas para el análisis textual, como `caption_limpio`, `palabras` y `palabras_limpias`.

5. Distribución de las publicaciones según formato

De las 100 publicaciones analizadas:

- 65 corresponden a imágenes
- 35 corresponden a videos

Por lo tanto:

65 % imágenes

35 % videos

Esta distribución resulta importante porque posteriormente permite analizar el nivel de interacción teniendo en cuenta que ambos formatos no tienen la misma cantidad de publicaciones dentro de la muestra.

6. Análisis de likes y comentarios


El análisis descriptivo de likeCount y commentCount mostró una distribución fuertemente asimétrica.

Likes

Estadístico Valor

Cantidad	100
Media	203,03
Mediana	27
Mínimo	2
Q1	16
Q3	44,75
Máximo	13.356

Figura 1. Distribución de publicaciones según nivel de interacción.



Interpretación: La distribución presenta una marcada asimetría, debido a que un número reducido de publicaciones concentra una cantidad muy elevada de interacciones respecto del resto.

Comentarios

Estadístico Valor

Cantidad	100
Media	3,13
Mediana	0
Mínimo	0
Q1	0
Q3	2
Máximo	122

La diferencia entre media y mediana evidencia la presencia de valores extremos.

7. Construcción de la métrica de interacciones

Para obtener una medida sencilla del nivel de respuesta generado por cada publicación se definió:

Interacciones = likeCount + commentCount

Esta métrica permite combinar las dos variables de interacción disponibles en el dataset.

Los resultados generales fueron:

Estadístico Interacciones

Cantidad	100
Media	206,16
Mediana	28,5
Q1	16
Q3	46,25
Máximo	13.478

El conjunto completo acumuló: **20.616 interacciones**

8. Asimetría y valores extremos

Uno de los principales hallazgos del análisis fue la fuerte diferencia entre la media y la mediana.

La media de interacciones fue de: **206,16**

Mientras que la mediana fue: **28,5**

Esto significa que el valor promedio se encuentra fuertemente influenciado por un grupo reducido de publicaciones con niveles de interacción excepcionalmente elevados.

Para comprobar este comportamiento se realizó un análisis adicional excluyendo las tres publicaciones con mayor cantidad de interacciones.

El resultado fue:

- Media con las 100 publicaciones: **206,16**
- Media excluyendo las 3 principales: **36,65**
- Mediana con las 100 publicaciones: **28,5**
- Mediana excluyendo las 3 principales: **27**

La reducción de la media de 206,16 a 36,65 muestra claramente el efecto de los valores extremos.

Por este motivo, para comparar grupos y temáticas se priorizó el uso de la **mediana**, ya que representa mejor el comportamiento central de una distribución fuertemente asimétrica.

9. Concentración de las interacciones

Otro de los resultados más relevantes fue la concentración de las interacciones en un grupo reducido de publicaciones.

Las 10 publicaciones con mayor cantidad de interacciones acumularon:


17.975 interacciones sobre un total de: **20.616**

Esto representa: **87,19 % de todas las interacciones de la muestra.**

Este resultado muestra que la interacción no se distribuye uniformemente entre las publicaciones analizadas en la muestra estadística.

Figura 2. Top 10 publicaciones por cantidad de interacciones.

Fuente: elaboración propia a partir de los datos recopilados y analizadas.



Interpretación: Se identifican las observaciones 47, 37 y 16 como outliers superiores significativos, cuya magnitud genera una marcada asimetría positiva que distorsiona la media de la muestra.

Las tres publicaciones con mayor cantidad de interacciones fueron:

Publicación	Interacciones
Espinillo	13.478
Tala	2.659
Sombra de Toro	924

Las tres primeras publicaciones acumularon en conjunto:

17.061 interacciones sobre las 20.616 totales.

Esto representa aproximadamente **82,75 % de todas las interacciones**.

10. Análisis de contenido

A partir del procesamiento de los textos se realizó un análisis de frecuencia de palabras.

Entre las palabras más frecuentes luego de la limpieza se encontraron:

- reserva – 44
- naturaleza – 33
- aprender – 23
- día – 21
- fundación – 20
- aves – 18
- Córdoba – 18
- gracias – 17
- experiencia – 16
- haciendo – 15
- lugar – 15
- Gilwell – 14
- Park – 14
- taller – 13
- esperamos – 12
- bosque – 11
- compromiso – 11
- nativas – 11
- jornada – 11
- sábado – 11

Estos resultados permiten observar que la comunicación de la cuenta se encuentra fuertemente relacionada con conceptos vinculados con:

- naturaleza;
- reservas;
- aprendizaje;
- actividades educativas;
- fauna;
- flora;
- Córdoba;
- experiencias al aire libre.

11. Asociación entre palabras

También se realizó un análisis de coocurrencia mediante pares de palabras.

Entre las asociaciones más frecuentes aparecieron:

Palabras	Frecuencia
Gilwell – Park	13
Gilwell – Reserva	13
Naturaleza – Reserva	13
Park – Reserva	13
Aprender – Haciendo	12
Córdoba – Reserva	11
Aprender – Fundación	11
Fundación – Haciendo	11
Contacto – Naturaleza	10

Palabras	Frecuencia
Córdoba - Gilwell	10
Córdoba - Park	10
Lugar - Reserva	10
Aves - Reserva	10
Aprender - Naturaleza	9
Aves - Reconocimiento	9
Aves - Taller	9

La coocurrencia permite complementar el análisis de frecuencia individual, ya que muestra qué conceptos aparecen habitualmente relacionados dentro de una misma publicación.

12. Clasificación temática

Para profundizar el análisis se incorporó una clasificación temática de las publicaciones.

Las categorías utilizadas fueron:

- Formación y aprendizaje
- Flora y naturaleza
- Fauna
- Ambiente y biodiversidad
- Actividades y experiencias
- Institucional / comunidad
- Sin caption

La distribución final fue:

Temática	Publicaciones
Formación y aprendizaje	31
Flora y naturaleza	22
Fauna	15
Sin caption	13
Actividades y experiencias	9
Institucional / comunidad	6
Ambiente y biodiversidad	4

La temática con mayor presencia fue **Formación y aprendizaje**, con 31 publicaciones.

Sin embargo, cantidad de publicaciones y nivel de interacción no necesariamente presentan el mismo comportamiento.

13. Interacciones por temática


Debido a la presencia de valores extremos, se utilizó la **mediana de interacciones** para comparar las temáticas.

Temática	Publicaciones	Mediana
Ambiente y biodiversidad	4	39
Actividades y experiencias	9	32
Flora y naturaleza	22	32,5
Fauna	15	30
Formación y aprendizaje	31	27
Institucional / comunidad	6	24
Sin caption	13	14

Estos valores permiten observar diferencias en el comportamiento central de las publicaciones de cada grupo.

Figura 3. Mediana de publicaciones por temática.

Fuente: elaboración propia a partir de los datos recopilados y analizadas.



Interpretación: La temática Flora y naturaleza requiere una consideración particular debido a la existencia de publicaciones extremadamente exitosas, especialmente las relacionadas con Espinillo, Tala y Sombra de Toro. Por este motivo, el promedio de esta categoría resulta muy superior a su mediana.

14. Clasificación de publicaciones de alto rendimiento

Para realizar determinados análisis comparativos se creó una clasificación binaria:

- Alto
- Resto

La definición se realizó utilizando la distribución de interacciones de la muestra.

El resultado fue:

- 25 publicaciones → Alto
- 75 publicaciones → Resto

Esta clasificación permitió estudiar qué proporción de publicaciones de cada temática, formato o día de la semana pertenece al grupo de mayor interacción.

15. Alto rendimiento según temática

La proporción de publicaciones clasificadas como "Alto" fue:


Temática	Publicaciones	Alto	% Alto
Ambiente y biodiversidad	4	2	50,0 %
Flora y naturaleza	22	10	45,45 %
Fauna	15	6	40,0 %
Formación y aprendizaje	31	6	19,35 %
Actividades y experiencias	9	1	11,11 %
Institucional / comunidad	6	0	0 %
Sin caption	13	0	0 %

Estos resultados muestran diferencias descriptivas entre las categorías.

Sin embargo, deben interpretarse considerando el tamaño de cada grupo. Por ejemplo, **Ambiente y biodiversidad tiene solamente cuatro publicaciones**, por lo que un cambio en una o dos publicaciones puede modificar significativamente su porcentaje.

Figura 4. Mediana de interacciones por temática.

Fuente: elaboración propia a partir de los datos recopilados y analizadas.



Interpretación: Las temáticas **Flora y naturaleza** y **Fauna** registran los promedios de interacción más elevados en alto rendimiento; la categoría **Ambiente y biodiversidad** muestra un desempeño equivalente, pero se excluye del inferencial por sesgo de tamaño muestral ($n = 4$).

16. Interacción según formato

La distribución de publicaciones de alto rendimiento según formato fue:

Formato Alto Resto Total

Imagen	18	47	65
Video	7	28	35

En términos porcentuales:


- Imagen: **27,69 % Alto**
- Video: **20,00 % Alto**

Los datos de esta muestra muestran una diferencia descriptiva entre ambos formatos.

Sin embargo, estos resultados no permiten establecer que el formato sea la causa de un mayor nivel de interacción.

Figura 5. Porcentaje de publicaciones de alto rendimiento según formato.

Fuente: elaboración propia a partir de los datos recopilados y analizadas.



Interpretación: Aunque las imágenes muestran un desempeño ligeramente superior al de los videos (~27.69% vs. ~20% del total de interacciones), la brecha no es estadísticamente significativa como para recomendar la priorización sistemática de un formato sobre el otro.

17. Interacción según día de la semana


La clasificación de publicaciones de alto rendimiento según día mostró:

Día	Publicaciones Alto	% Alto
Viernes	14	35,71 %
Jueves	15	33,33 %
Domingo	13	30,77 %
Miércoles	22	22,73 %
Lunes	14	21,43 %

Día	Publicaciones	Alto	% Alto
Martes	12	2	16,67 %
Sábado	10	1	10,00 %

Figura 6. Publicaciones de alto rendimiento por día.

Fuente: elaboración propia a partir de los datos recopilados y analizadas.



Interpretación: Si bien el miércoles concentra la mayor frecuencia de publicaciones, los días jueves, viernes y domingo registran la mayor proporción de contenidos de alto rendimiento (outliers positivos), sugiriendo una mayor eficiencia de interacción hacia el final de la semana.

Estos resultados deben interpretarse como **patrones observados en las 100 publicaciones analizadas**, no como una relación solamente causal entre día de publicación e interacción.

18. Interacción según horario

También se analizó la distribución de las publicaciones según franjas horarias.

Los datos obtenidos fueron:

Franja	Alto	Resto
Madrugada	1	1
Mañana	7	19
Mediodía	5	14
Tarde	3	11
Noche	9	30

La noche concentró la mayor cantidad absoluta de publicaciones clasificadas como "Alto", aunque también representa la franja con mayor cantidad total de publicaciones.

Por este motivo, nuevamente resulta más adecuado comparar proporciones que cantidades absolutas.

19. Tema × formato × rendimiento

Se realizó además un análisis conjunto entre:


- Temática;
- Formato;
- Nivel de interacción.

Esto permitió observar que el comportamiento del formato no es uniforme entre todas las categorías.

Por ejemplo, algunas temáticas presentan diferencias entre imágenes y videos, mientras que otras cuentan con cantidades reducidas de publicaciones en alguno de los formatos.

Figura 7. Publicaciones de alto rendimiento por día.

Fuente: elaboración propia a partir de los datos recopilados y analizadas.



Interpretación: El alto rendimiento está fuertemente condicionado por la temática y la elección del formato: Fauna alcanza su máximo potencial en formato Video (~55%), mientras que Flora y naturaleza lo hace exclusivamente mediante Imagen (~55%). Por su parte, Ambiente y biodiversidad mantiene un comportamiento balanceado entre ambos formatos (50%) pero como se explica en el grafico anterior por su propio volumen no es representativo.

Este punto es importante porque demuestra que analizar únicamente "imagen vs. video" puede ocultar diferencias relacionadas con el tipo de contenido.

Por lo tanto, el análisis multidimensional permite obtener una visión más completa del comportamiento de las publicaciones.

20. Análisis de hashtags

Se analizó también la cantidad de hashtags utilizados. Los resultados fueron:

Estadístico Hashtags

Media	1,21
Mediana	0
Mínimo	0
Q3	3
Máximo	5

La mitad de las publicaciones analizadas presentó **0 hashtags**.

El análisis de interacción según cantidad de hashtags mostró diferencias importantes en los promedios, particularmente en publicaciones con dos y cuatro hashtags.

Sin embargo, estos resultados estuvieron fuertemente condicionados por valores extremos.

Por este motivo, el análisis de hashtags se considera principalmente **exploratorio** y no permite concluir que una determinada cantidad de hashtags produzca mayor interacción.

21. Longitud de los captions

La longitud de los textos presentó los siguientes resultados:

Estadístico Caracteres

Media	320,56
Mediana	248
Mínimo	0
Q3	403,75
Máximo	1.635

Se analizó además la correlación entre longitud del caption y cantidad de likes.

El coeficiente obtenido fue:

$$r = -0,1017$$

Este valor representa una relación lineal negativa **muy débil** entre ambas variables dentro de esta muestra.

Por lo tanto, no se observa una relación lineal fuerte entre la longitud del texto y la cantidad de likes.

22. Principales hallazgos

A partir del análisis exploratorio pueden destacarse los siguientes resultados:

1. Las interacciones presentan una distribución altamente asimétrica

La media fue de 206,16 interacciones mientras que la mediana fue de 28,5. Esto evidencia la influencia de valores extremos.

2. Las interacciones están fuertemente concentradas

El Top 10 de publicaciones representa el **87,19 % del total de interacciones**.

3. Las tres publicaciones principales tienen un peso excepcional

Espinillo, Tala y Sombra de Toro acumularon conjuntamente aproximadamente **82,75 % de las interacciones**.

4. Flora y naturaleza concentra algunas de las publicaciones de mayor interacción

Las tres publicaciones con mayor cantidad de interacciones pertenecen a esta temática.

5. La cantidad de publicaciones no implica necesariamente mayor interacción

Formación y aprendizaje fue la categoría más frecuente, con 31 publicaciones, pero su mediana de interacción fue inferior a la de varias categorías con menor cantidad de publicaciones.

6. Se observan diferencias entre formatos

Dentro de esta muestra, el 27,69 % de las imágenes fue clasificado como "Alto", frente al 20 % de los videos.

7. Existen diferencias según el día

Viernes, jueves y domingo presentaron los mayores porcentajes de publicaciones clasificadas como "Alto".

8. La longitud del caption no muestra una relación lineal fuerte con los likes

La correlación obtenida fue de **-0,1017**.

9. El contenido presenta una fuerte identidad temática

Las palabras más frecuentes están relacionadas principalmente con naturaleza, reservas, aprendizaje, fauna, flora, Córdoba y actividades educativas.

23. Limitaciones del análisis

Una parte importante de cualquier proyecto de Ciencia de Datos consiste en reconocer sus limitaciones.

En este caso deben considerarse las siguientes:

Tamaño de muestra

El análisis utiliza solamente las **100 publicaciones más recientes disponibles en el dataset**. Por lo tanto, los resultados describen esta muestra y no necesariamente todo el historial de la cuenta.

Valores extremos

La presencia de publicaciones con miles de interacciones genera una distribución muy asimétrica. Esto obliga a complementar la media con medidas robustas como la mediana.

Falta de métricas de alcance

El dataset contiene likes y comentarios, pero no incluye métricas como:

- alcance;
- impresiones;
- reproducciones completas;
- compartidos;
- guardados;
- crecimiento de seguidores.

Por lo tanto, la interacción analizada no representa necesariamente el alcance total de cada publicación.

Tamaño reducido de algunas categorías

Algunas temáticas tienen pocos registros. Por ejemplo: Ambiente y biodiversidad → 4 publicaciones.

Por lo tanto, porcentajes elevados en categorías pequeñas deben interpretarse con cautela.

Asociación no implica causalidad

Los análisis realizados permiten encontrar patrones y asociaciones, pero no permiten afirmar que un determinado día, horario, formato o temática sea la causa directa de un mayor nivel de interacción.

24. Conclusiones

El análisis de las 100 publicaciones permitió identificar diferentes patrones relacionados con el contenido y el comportamiento de las interacciones.

Uno de los principales resultados fue comprobar que las interacciones presentan una **distribución fuertemente asimétrica**, donde un grupo reducido de publicaciones concentra una proporción muy importante de la respuesta obtenida.

El hecho de que el Top 10 represente el **87,19 % de las interacciones** demuestra que el rendimiento de las publicaciones no se distribuye de manera uniforme.

También se identificó una relación descriptiva entre determinadas temáticas y niveles superiores de interacción. En particular, las publicaciones relacionadas con **Flora y naturaleza** concentran varias de las publicaciones con mayor rendimiento de toda la muestra.

El análisis textual permitió complementar esta información mostrando que conceptos como **reserva, naturaleza, aprendizaje, aves, Córdoba, fundación, taller y especies nativas** forman parte de los principales ejes comunicacionales de las publicaciones.

Desde el punto de vista metodológico, uno de los aprendizajes más importantes del proyecto fue la necesidad de utilizar diferentes medidas estadísticas para interpretar correctamente los datos. La diferencia entre una media de **206,16** y una mediana de **28,5** demuestra que utilizar únicamente el promedio podría generar una interpretación poco representativa del comportamiento habitual de las publicaciones.

Por este motivo, el análisis combinó estadísticas descriptivas, medidas robustas, clasificación temática, análisis temporal, análisis de formato y técnicas básicas de procesamiento de lenguaje.

En conjunto, el proyecto permitió transformar un conjunto de datos de publicaciones de redes sociales en un análisis estructurado capaz de identificar **patrones de contenido, concentración de interacciones y características asociadas al rendimiento de las publicaciones.**

25. Herramientas utilizadas

El proyecto fue desarrollado principalmente mediante:

- Python
- Pandas
- Matplotlib
- Google Colab
- Técnicas de limpieza y transformación de datos
- Estadística descriptiva
- Análisis exploratorio de datos
- Procesamiento básico de texto
- Análisis de frecuencia y coocurrencia
- Agrupamiento y clasificación temática
- Visualización de datos

Autor: Marcelo Javier Werner